T.C.

BURSA TEKNİK ÜNİVERSİTESİ

Mühendislik ve Doğa Bilimleri Fakültesi

Yapay Zekâ ve Makine Öğrenmesi Bölümü

LAB 3: Logistic Regression ve Linear Regression

Performans Karşılaştırması

Ders: YZM0206 – Makine Öğrenmesi

Öğrenci Adı Soyadı:	Halil İbrahim Kutmur
Öğrenci Numarası:	24458667010
Bölüm:	Yapay Zekâ ve Makine Öğrenmesi
Derece:	Lisans
Tarih:	09.04.2026

Bursa, 2026

İçindekiler

1 Giriş **2**

2 Veri Seti **2**

3 Veri Ön İşleme **3**
3.1 Gereksiz Sütunların Kaldırılması . . . 3
3.2 Özellik ve Hedef Ayrımı . . . 3
3.3 Eğitim–Test Ayrımı . . . 3
3.4 Özellik Ölçekleme (Feature Scaling) . . . 4

4 Logistic Regression Modeli **4**
4.1 Teorik Arka Plan . . . 4
4.2 Model Eğitimi ve Tahmin . . . 4
4.3 Performans Sonuçları . . . 5

5 Linear Regression Modeli **5**
5.1 Teorik Arka Plan . . . 5
5.2 Model Eğitimi ve Tahmin . . . 6
5.3 Ham Çıktı Analizi . . . 6
5.4 Performans Sonuçları . . . 7

6 Karşılaştırma Analizi **8**
6.1 Performans Metrikleri Karşılaştırması . . . 8
6.2 Hangi Model Daha İyi Performans Gösterdi? . . . 9
6.3 Linear Regression Neden Bu Problem İçin Uygun Değildir? . . . 9
6.4 Logistic Regression Neden Daha Doğru Sonuç Verdi? . . . 10
6.5 Linear Modelin Çıktılarının Problemli Olmasının Sebebi . . . 10

7 Görselleştirme: Karar Sınırı (Decision Boundary) **10**

8 Sonuç **12**

1 Giriş

Bu laboratuvar çalışmasında, aynı veri seti üzerinde **Logistic Regression** ve **Linear Regression** modelleri eğitilerek performansları karşılaştırılmıştır. Amaç, sınıflandırma problemlerinde doğru algoritma seçiminin önemini göstermektir.

Linear Regression, sürekli (continuous) değerleri tahmin etmek için tasarlanmış bir regresyon algoritmasıdır. **Logistic Regression** ise, sigmoid fonksiyonu kullanarak çıktıları $[0, 1]$ aralığına sınırlayıp sınıflandırma yapan bir algoritmadır.

Bu çalışmada her iki modelin aynı ikili sınıflandırma problemi üzerindeki performansı, çeşitli metrikler (Accuracy, Precision, Recall, F1-Score) ve görselleştirmeler (Confusion Matrix, Decision Boundary) ile değerlendirilmiştir.

2 Veri Seti

Çalışmada **Social_Network_Ads.csv** veri seti kullanılmıştır. Bu veri seti, bir sosyal ağ üzerinden yapılan reklamlara kullanıcıların satın alma davranışlarını içermektedir.

Tablo 1: Veri seti özellikleri

Sütun Adı	**Türü**	**Açıklama**
User ID	Kategorik	Kullanıcı kimliği (kaldırıldı)
Gender	Kategorik	Cinsiyet (kaldırıldı)
Age	Sayısal	Kullanıcının yaşı
EstimatedSalary	Sayısal	Tahmini maaş
Purchased	İkili	Satın alma durumu (0 veya 1)

Veri seti toplam **400 örnek** içermektedir. Hedef değişken olan `Purchased` sütunu ikili (binary) yapıdadır:

- **0:** Satın almadı (257 örnek)
- **1:** Satın aldı (143 örnek)

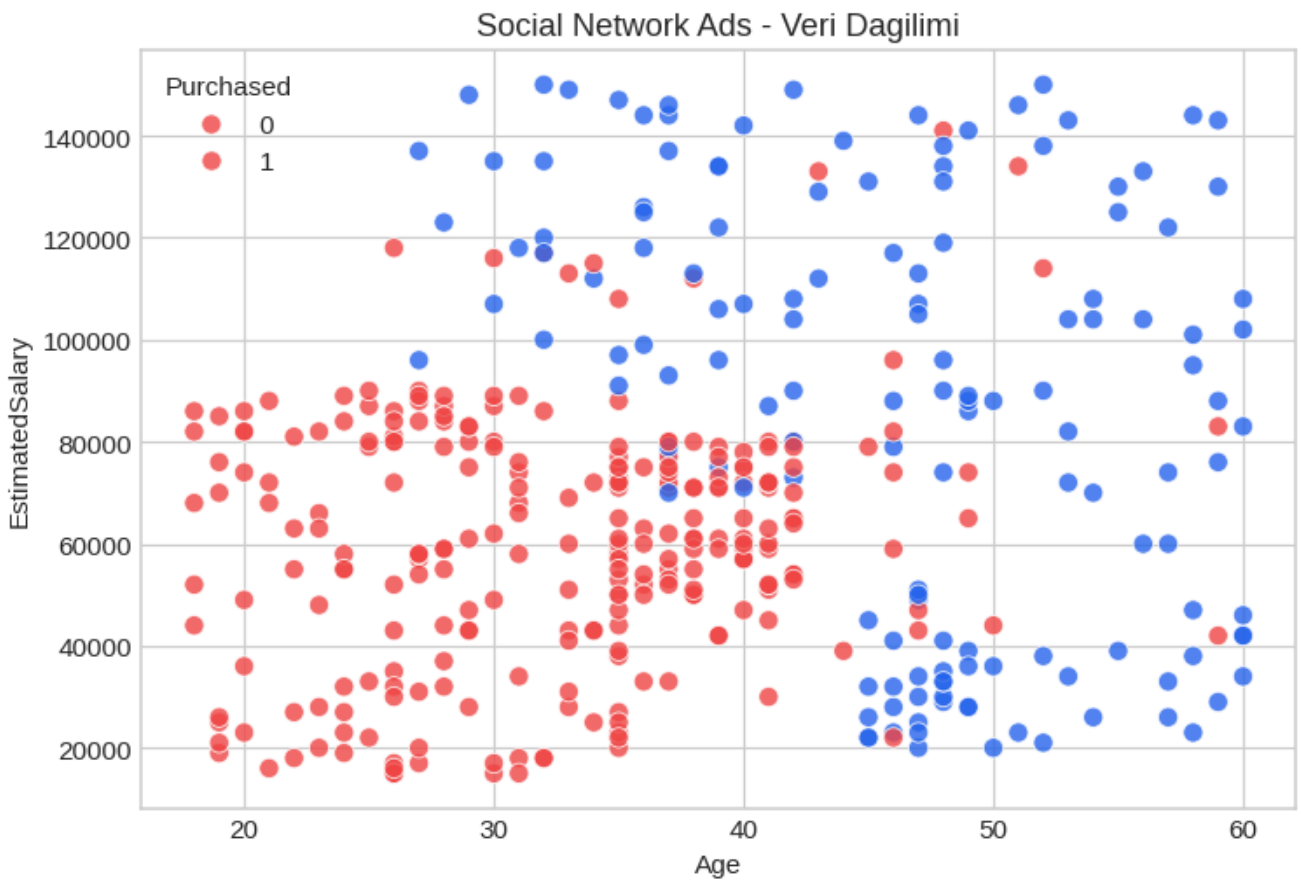

Şekil 1: Veri setinin Age ve EstimatedSalary özelliklerine göre dağılımı

Şekil 1'de görüldüğü gibi, yaşı yüksek ve maaşı yüksek olan kullanıcıların satın alma eğilimi daha fazladır.

3 Veri Ön İşleme

Veri ön işleme aşamasında aşağıdaki adımlar uygulanmıştır:

3.1 Gereksiz Sütunların Kaldırılması

`User ID` ve `Gender` sütunları, modelleme için bilgi taşımadığından kaldırılmıştır. Geriye yalnızca `Age` ve `EstimatedSalary` özellikleri kalmıştır.

3.2 Özellik ve Hedef Ayrımı

- **X (Özellikler):** Age, EstimatedSalary $\rightarrow$ (400×2) boyutlu matris
- **y (Hedef):** Purchased $\rightarrow$ $(400,)$ boyutlu vektör

3.3 Eğitim–Test Ayrımı

Veri seti **%75 eğitim** ve **%25 test** olarak ayrılmıştır (`random_state=57`):

Tablo 2: Eğitim–Test ayrımı

Küme	**Örnek Sayısı**
Eğitim seti	300
Test seti	100

3.4 Özellik Ölçekleme (Feature Scaling)

`StandardScaler` kullanılarak özellikler standartlaştırılmıştır. Bu işlem, her özelliğin ortalamasını 0, standart sapmasını 1 yaparak farklı ölçeklerdeki özelliklerin modeli olumsuz etkilemesini önler:

$$z = \frac{x - \mu}{\sigma} \tag{1}$$

Bu adım özellikle `EstimatedSalary` (binlerle ifade edilen) ve `Age` (onlarla ifade edilen) arasındaki ölçek farkını gidermek için kritik öneme sahiptir.

4 Logistic Regression Modeli

4.1 Teorik Arka Plan

Logistic Regression, ikili sınıflandırma problemleri için tasarlanmış bir algoritmadır. Sigmoid (logistic) fonksiyonunu kullanarak çıktıları $[0, 1]$ aralığına dönüştürür:

$$\sigma(z) = \frac{1}{1 + e^{-z}} \tag{2}$$

burada $z = w_1x_1 + w_2x_2 + b$ doğrusal kombinasyondur. Tahmin fonksiyonu:

$$\hat{y} = \sigma(w^T x + b) = \frac{1}{1 + e^{-(w^T x + b)}} \tag{3}$$

Kayıp fonksiyonu olarak **Binary Cross-Entropy** (Log Loss) kullanılır:

$$J(w, b) = -\frac{1}{n} \sum_{i=1}^{n} [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)] \tag{4}$$

4.2 Model Eğitimi ve Tahmin

Logistic Regression modeli, `scikit-learn` kütüphanesi kullanılarak eğitilmiştir. Model, eğitim verisinden öğrendiği ağırlıklar ile test verisi üzerinde tahmin yapmıştır.

```
from sklearn.linear_model import LogisticRegression

log_reg = LogisticRegression(random_state=42)
log_reg.fit(X_train_scaled, y_train)
```

```
y_pred_log = log_reg.predict(X_test_scaled)
```

Listing 1: Logistic Regression modeli

4.3 Performans Sonuçları

Tablo 3: Logistic Regression – Performans metrikleri

Metrik	Değer
Accuracy	0.8600
Precision	0.8788
Recall	0.7436
F1-Score	0.8056

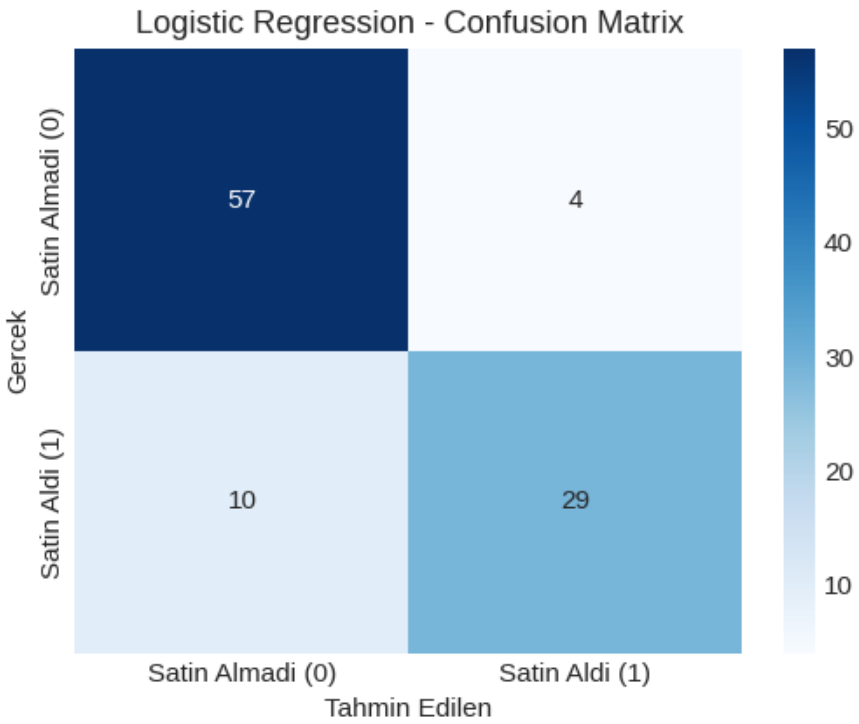

Şekil 2: Logistic Regression – Confusion Matrix

Şekil 2'de görüldüğü gibi, Logistic Regression modeli 100 test örneğinden **86**'sını doğru sınıflandırmıştır. Model, 61 gerçek negatif örnekten 57'sini, 39 gerçek pozitif örnekten ise 29'unu doğru tahmin etmiştir.

5 Linear Regression Modeli

5.1 Teorik Arka Plan

Linear Regression, sürekli değerleri tahmin etmek için tasarlanmış bir regresyon algoritmasıdır:

$$\hat{y} = w_1 x_1 + w_2 x_2 + b \tag{5}$$

Kayıp fonksiyonu olarak **Mean Squared Error (MSE)** kullanılır:

$$J(w, b) = \frac{1}{n} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 \tag{6}$$

Bu modelin çıktısı $(-\infty, +\infty)$ aralığında herhangi bir reel sayı olabilir. Sınıflandırma için kullanıldığında, çıktılar bir eşik değeri (threshold) ile sınıfa dönüştürülmelidir.

5.2 Model Eğitimi ve Tahmin

Linear Regression modeli eğitildikten sonra, ham çıktılar 0.5 eşik değeri kullanılarak ikili sınıflara dönüştürülmüştür.

```python
from sklearn.linear_model import LinearRegression

lin_reg = LinearRegression()
lin_reg.fit(X_train_scaled, y_train)
y_pred_lin_raw = lin_reg.predict(X_test_scaled)
y_pred_lin = (y_pred_lin_raw >= 0.5).astype(int)
```

Listing 2: Linear Regression modeli ve threshold uygulaması

5.3 Ham Çıktı Analizi

Linear Regression modelinin ham çıktıları incelendiğinde ciddi bir problem görülmektedir:

Tablo 4: Linear Regression – Ham çıktı istatistikleri

İstatistik	**Değer**
Minimum çıktı	-0.2819
Maksimum çıktı	1.0037
$[0, 1]$ dışında kalan tahmin	19 / 100
0'dan küçük tahmin sayısı	18
1'den büyük tahmin sayısı	1

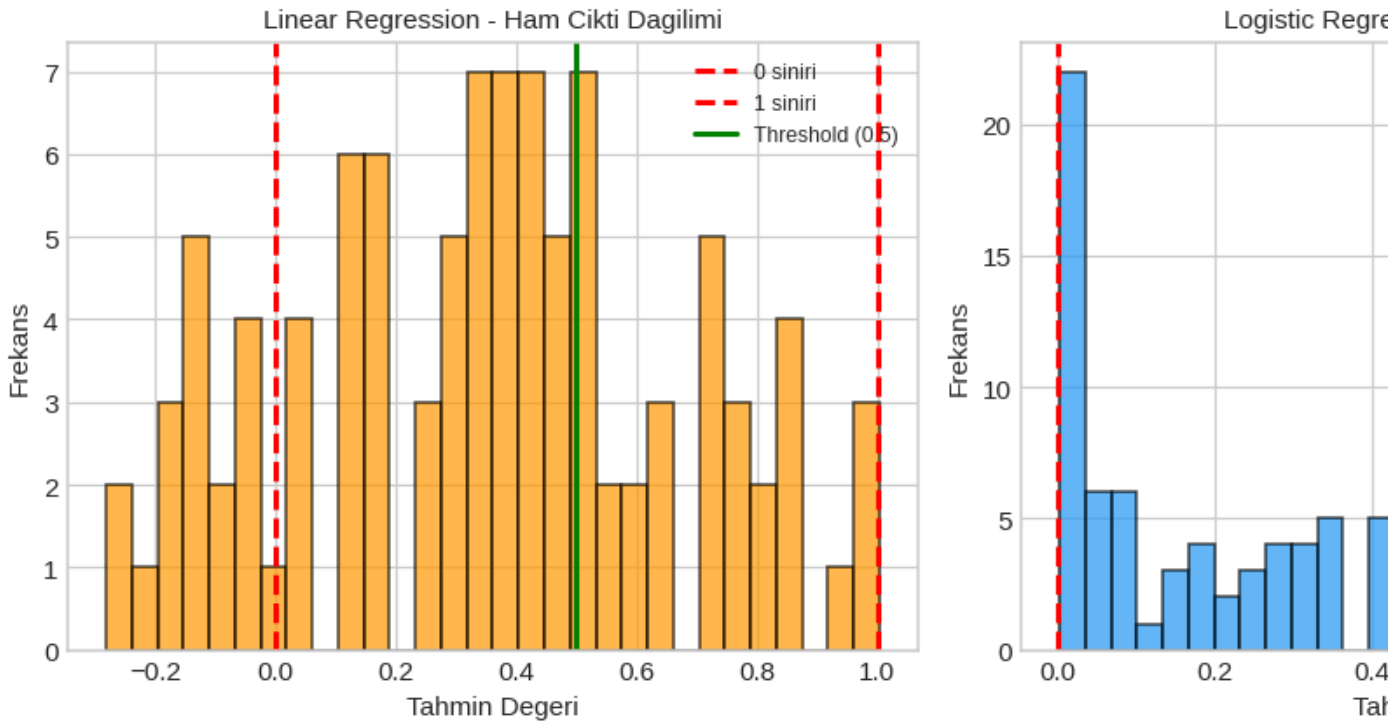

Şekil 3: Linear Regression ham çıktı dağılımı (sol) ve Logistic Regression olasılık dağılımı (sağ)

Şekil 3'de görüldüğü gibi, Linear Regression'ın çıktıları $[0, 1]$ aralığının dışına taşmaktadır (kırmızı kesikli çizgiler). Bu durum, çıktıların olasılık olarak yorumlanamayacağını göstermektedir. Öte yandan, Logistic Regression'ın çıktıları sigmoid fonksiyonu sayesinde tamamen $[0, 1]$ aralığında kalmaktadır.

5.4 Performans Sonuçları

Tablo 5: Linear Regression – Performans metrikleri

Metrik	**Değer**
Accuracy	0.8300
Precision	0.8929
Recall	0.6410
F1-Score	0.7463

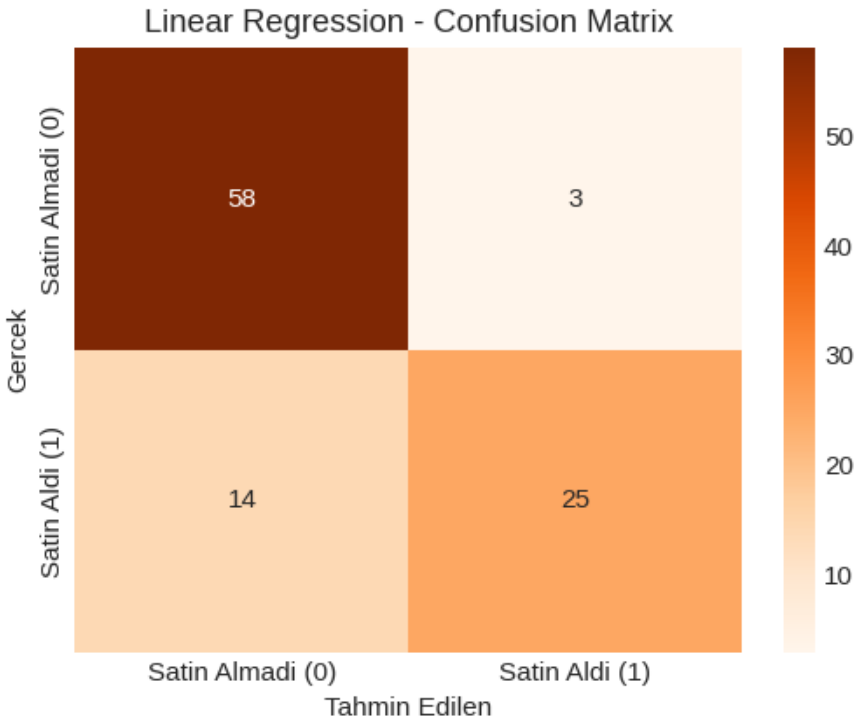

Şekil 4: Linear Regression – Confusion Matrix

Linear Regression modeli 100 test örneğinden **83**'ünü doğru sınıflandırmıştır. Özellikle pozitif sınıfı yakalamada (Recall) Logistic Regression'a kıyasla belirgin bir düşüş gözlemlenmektedir.

6 Karşılaştırma Analizi

6.1 Performans Metrikleri Karşılaştırması

Tablo 6: Model performans karşılaştırması

Metrik	Logistic Regression	Linear Regression	Fark
Accuracy	**0.8600**	0.8300	+0.0300
Precision	0.8788	**0.8929**	−0.0141
Recall	**0.7436**	0.6410	+0.1026
F1-Score	**0.8056**	0.7463	+0.0593

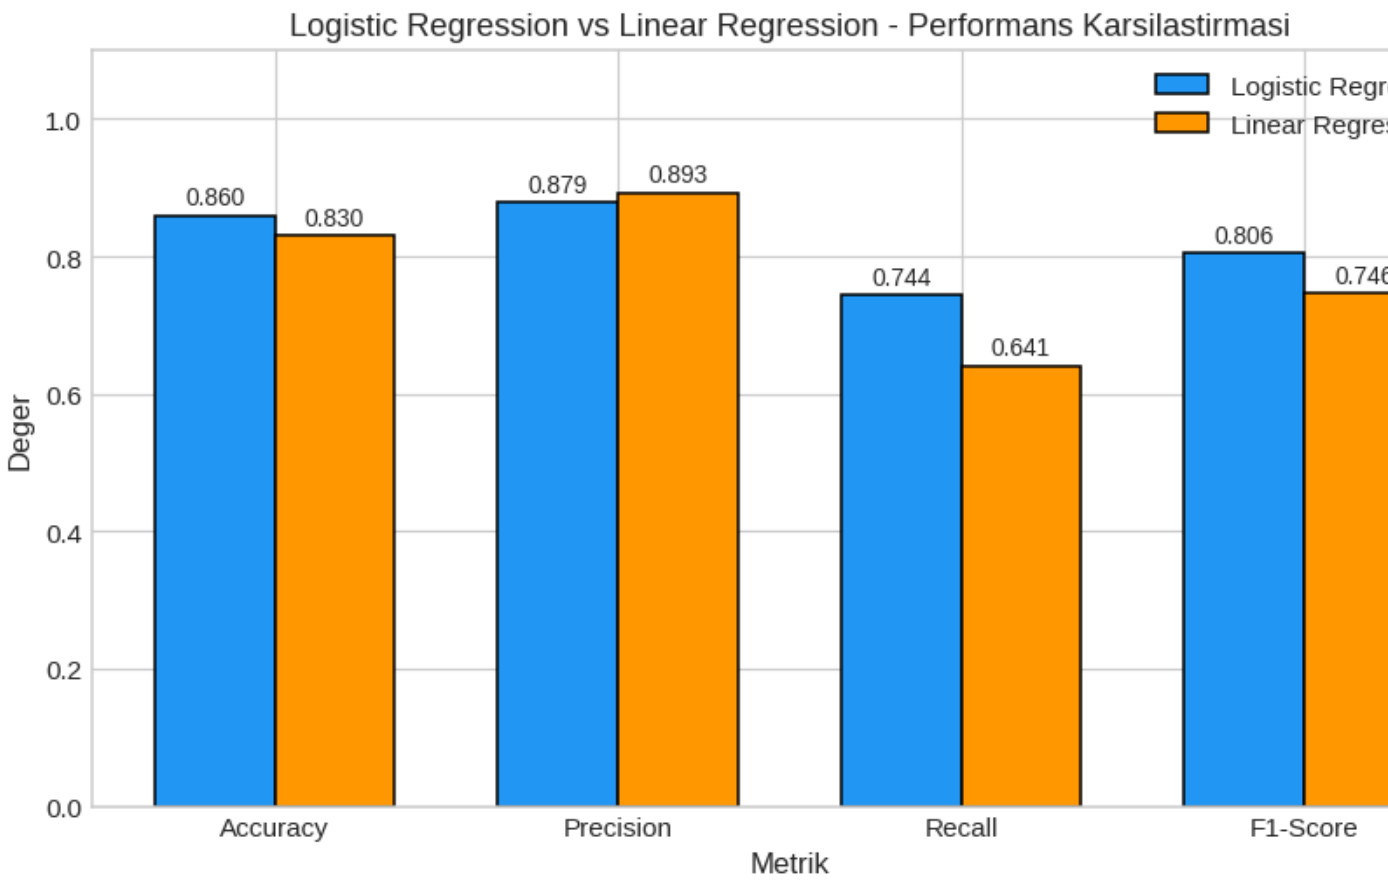

Şekil 5: Performans metriklerinin görsel karşılaştırması

Tablo 6 ve Şekil 5'de görüldüğü gibi, **Logistic Regression** modeli Accuracy, Recall ve F1-Score metriklerinde Linear Regression'a üstünlük sağlamıştır. Precision metriğinde Linear Regression marjinal olarak daha iyi olsa da, genel performansta Logistic Regression açık ara öndedir.

6.2 Hangi Model Daha İyi Performans Gösterdi?

Logistic Regression modeli tüm ana metriklerde (Accuracy, Recall, F1-Score) daha iyi performans göstermiştir. Özellikle **Recall** metriğinde **%10.26'lık** belirgin bir fark görülmektedir. Bu, Logistic Regression'ın gerçekte satın alan kişileri yakalamada çok daha başarılı olduğunu göstermektedir.

6.3 Linear Regression Neden Bu Problem İçin Uygun Değildir?

Linear Regression'ın sınıflandırma problemleri için uygun olmamasının temel nedenleri şunlardır:

1. **Sınırsız çıktı aralığı:** Linear Regression, $\hat{y} = w^T x + b$ formülü ile $(-\infty, +\infty)$ aralığında değerler üretir. Bu çalışmada -0.28'den 1.00'a kadar değerler gözlemlenmiştir. Negatif bir olasılık ya da 1'den büyük bir olasılık fiziksel olarak anlamsızdır.

2. **Uygun olmayan kayıp fonksiyonu:** MSE (Mean Squared Error), sürekli değerler için optimize edilmiştir. Sınıflandırma problemlerinde Cross-Entropy gibi olasılıksal

kayıp fonksiyonları çok daha uygundur.

3. **Doğrusal karar sınırının yetersizliği:** Linear Regression, $[0, 1]$ aralığına göre değil, genel hata minimizasyonuna göre karar sınırı oluşturur. Bu nedenle sınır, sınıflandırma için optimal değildir.
4. **Aykırı değerlere duyarlılık:** Aykırı değerler (outlier) doğrusal modelin eğimini ve dolayısıyla karar sınırını büyük ölçüde değiştirebilir.

6.4 Logistic Regression Neden Daha Doğru Sonuç Verdi?

Logistic Regression'ın daha başarılı olmasının nedenleri:

1. **Sigmoid fonksiyonu:** Çıktıları otomatik olarak $[0, 1]$ aralığına dönüştürerek geçerli olasılık değerleri üretir.
2. **Uygun kayıp fonksiyonu:** Cross-Entropy kayıp fonksiyonu, sınıflandırma problemleri için matematiksel olarak optimal parametreleri bulmayı sağlar.
3. **Maximum Likelihood Estimation:** Parametreler, verideki olasılık dağılımına en uygun şekilde öğrenilir.
4. **Doğal karar sınırı:** Model, $P(y = 1|x) = 0.5$ noktasında doğal bir karar sınırı oluşturur; bu sınır sınıflandırma için optimize edilmiştir.

6.5 Linear Modelin Çıktılarının Problemli Olmasının Sebebi

Linear Regression'ın çıktıları, $y = w_1x_1 + w_2x_2 + b$ şeklinde basit bir doğrusal denklemden elde edilir. Bu denklemin sonucu:

- Herhangi bir reel sayı olabilir ($-\infty$ ile $+\infty$ arası).
- Olasılık olarak yorumlanamaz (negatif veya 1'den büyük değerler anlamsızdır).
- Threshold ile sınıfa çevirme, modelin doğal yapısında olmayan yapay bir zorlama oluşturur.
- OLS (Ordinary Least Squares) yöntemi, sınıf etiketleri arasındaki karesel hatayı minimize eder; bu ise sınıflandırma için uygun bir optimizasyon kriteri değildir.

Bu çalışmada, test setindeki **100 tahminin 19'u** $[0, 1]$ aralığının dışında kalmıştır; bu durum modelin sınıflandırma için teorik olarak uygunsuzluğunu somut biçimde kanıtlamaktadır.

7 Görselleştirme: Karar Sınırı (Decision Boundary)

Karar sınırı, modelin iki sınıfı birbirinden ayırdığı bölgeyi gösterir. Aşağıdaki görsellerde her iki modelin karar sınırları hem eğitim hem de test seti üzerinde karşılaştırılmaktadır.

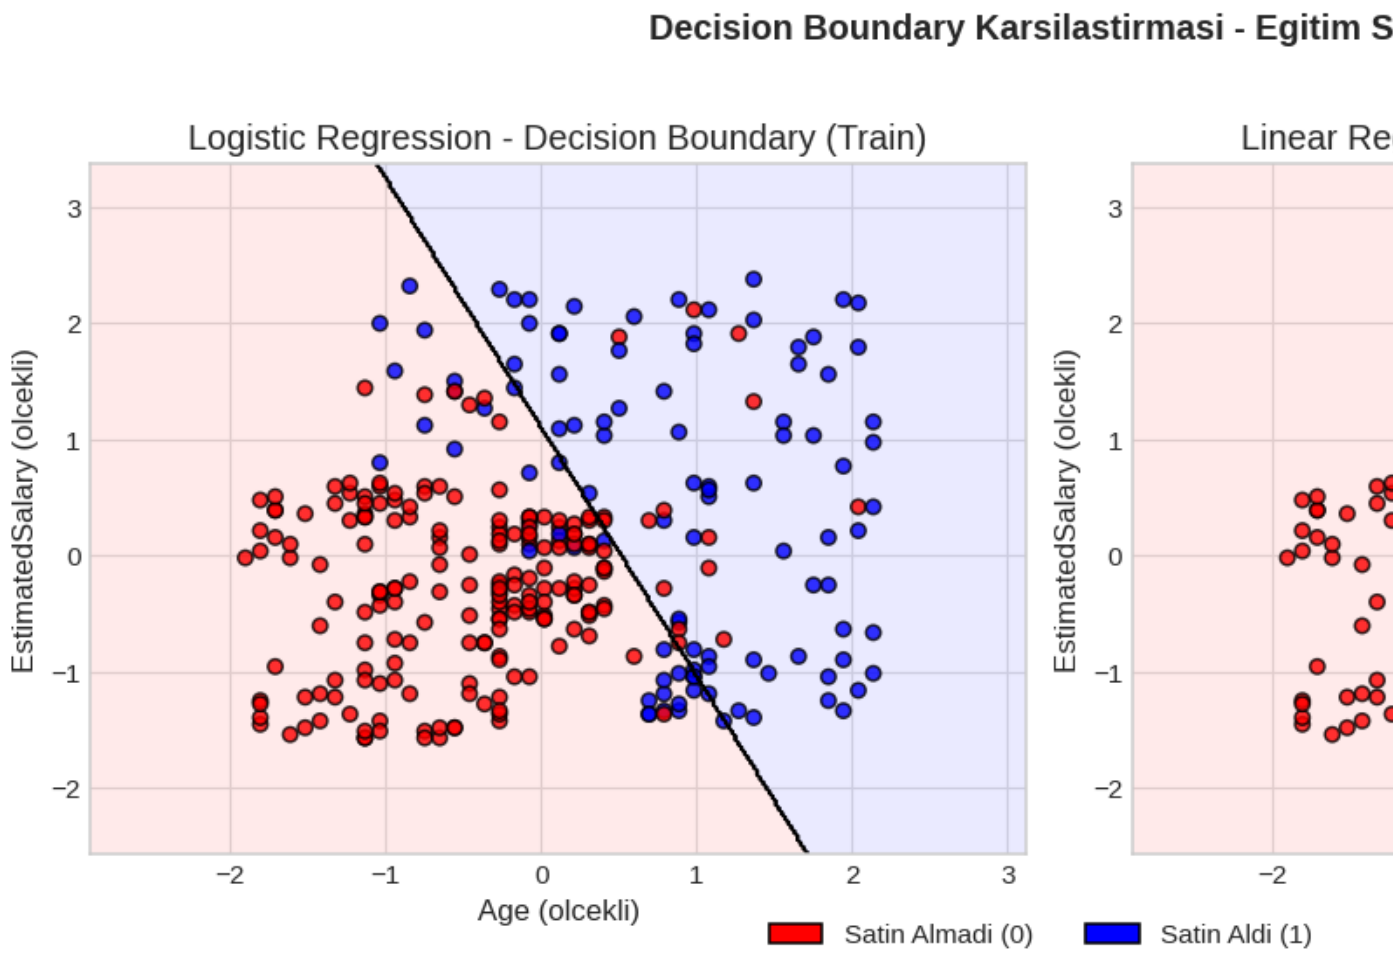

Şekil 6: Karar sınırı karşılaştırması – Eğitim seti

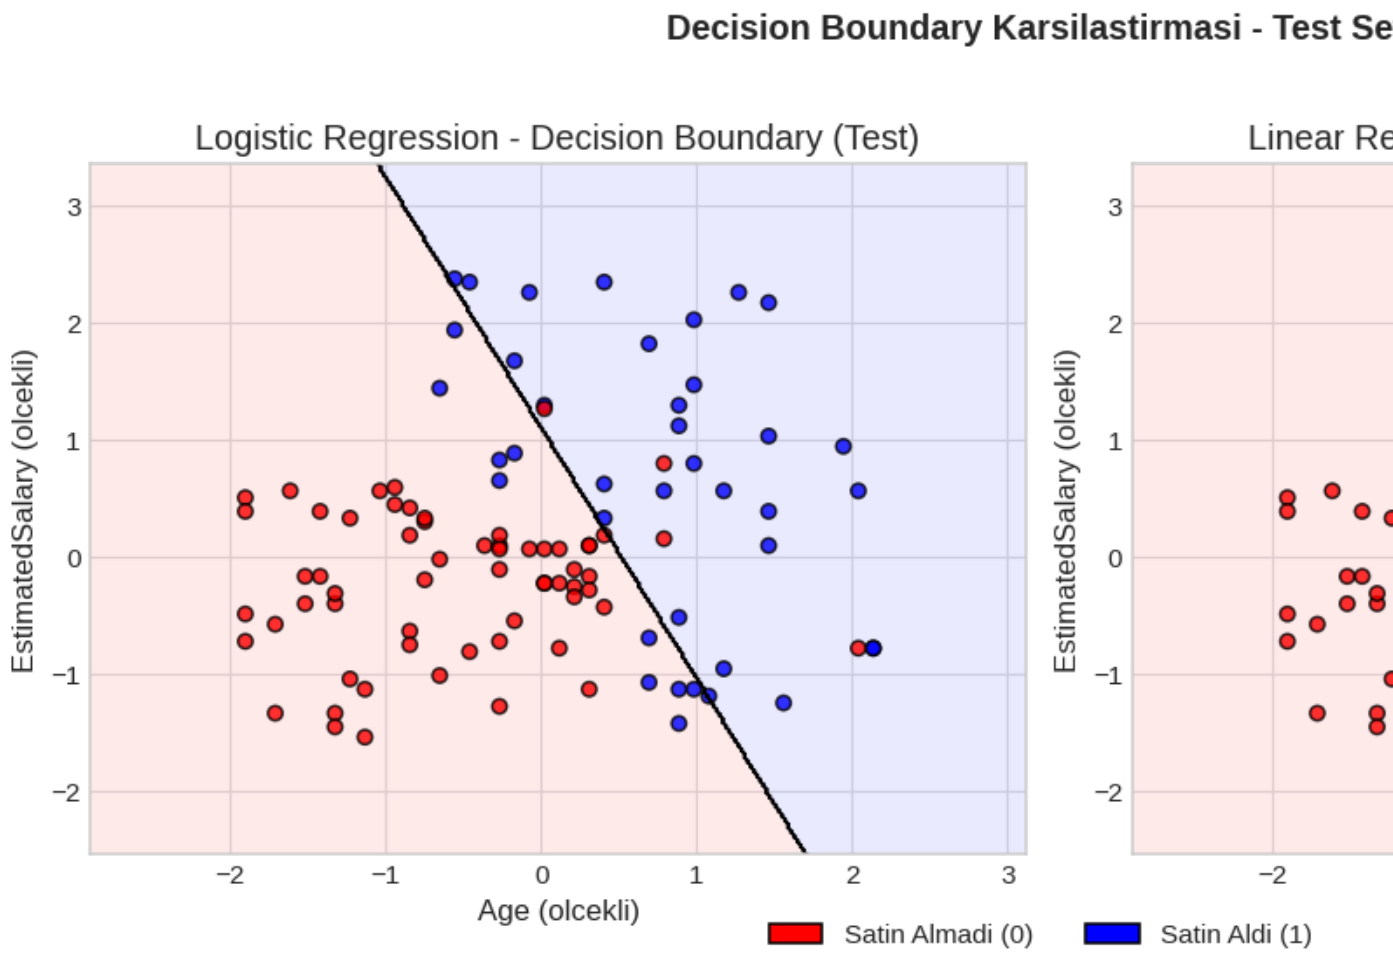

Şekil 7: Karar sınırı karşılaştırması – Test seti

Şekil 6 ve Şekil 7 incelendiğinde:

- **Logistic Regression**, sınıfları daha uygun bir şekilde ayıran bir karar sınırı oluşturmuştur. Kırmızı ve mavi bölgeler arasındaki geçiş, verideki gerçek sınıf dağılımına daha uyumludur.
- **Linear Regression**'ın karar sınırı ise doğrusal bir çizgidir ve sınıflandırma için optimize edilmediğinden bazı bölgelerde hatalı ayrımlar yapmaktadır.
- Her iki modelin karar sınırları doğrusal olmasına rağmen, Logistic Regression'ın sınırı sınıflandırma için optimize edilmiş olduğundan daha isabetlidir.

8 Sonuç

Bu laboratuvar çalışmasında, sınıflandırma problemlerinde doğru algoritma seçiminin kritik önemi ortaya konmuştur. Elde edilen bulgular aşağıda özetlenmektedir:

1. **Logistic Regression**, sınıflandırma problemleri için özel olarak tasarlanmış bir algoritmadır. Sigmoid fonksiyonu ve cross-entropy kayıp fonksiyonu sayesinde, ikili sınıflandırmada tutarlı ve anlamlı sonuçlar üretir.

2. **Linear Regression**, sürekli değer tahmini için tasarlanmıştır. Sınıflandırma problemlerinde kullanıldığında çıktılar $[0, 1]$ aralığının dışına taşabilir ve bu durum olasılıksal yorumlama açısından sorun oluşturur.
3. Performans karşılaştırmasında Logistic Regression, **Accuracy'de %3**, **Recall'da %10.26** ve **F1-Score'da %5.93** daha iyi sonuç vermiştir.
4. Test setindeki 100 tahminin 19'unun $[0, 1]$ aralığının dışında kalması, Linear Regression'ın sınıflandırma için teorik olarak uygunsuz olduğunu somut biçimde göstermiştir.

Sonuç olarak: Sınıflandırma problemlerinde Logistic Regression (veya diğer sınıflandırma algoritmaları) tercih edilmelidir. Her ne kadar Linear Regression threshold ile sınıflandırmaya zorlanabilse de, bu yaklaşım hem teorik hem de pratik açıdan uygun değildir.